

Clasificadores

Amador Mendoza Jesùs

11 de mayo de 2026

Índice

1. Introducció	3
2. Estadística descriptiva	3
3. Clasificador Random Forest	4
4. clasificador KNN	5
5. Desviación estandar a largo y corto plazo	5
6. Resultados	6
7. Conclusión	11

1. Introducció

El presente trabajo es una investigación y aplicación de métodos preliminares para el manejo de datos no lineales y su posterior análisis. El fin es entender cómo diferentes métodos no lineales pueden ayudar a comprender mejor los datos que estamos visualizando y, de igual manera, cómo podrían ayudarnos a detectar tendencias o diferencias significativas entre una población control y una población con Deterioro Cognitivo Leve (DCL). Para ello, se emplearán clasificadores como k-vecinos más cercanos (k-NN) con el objetivo de evaluar la separabilidad de ambos grupos en espacios de características reconstruidos a partir de geometrías no lineales.

2. Estadística descriptiva

Antes de profundizar en el tema es importante tener una forma de dimensionar los datos con los que estamos trabajando mediante medidas de tendencia central y dispersión. A continuación, se presentan los momentos estadísticos que permiten entender la distribución global de las muestras.

Cuadro 1: Estadísticas Descriptivas por sujeto control (Parte 1/2)

Métrica	EMV	GH2	GUR	JAL	JAN
count	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6
mean	-0.192	1.23	-0.982	-1.11	-0.731
std	5.99	3.24	5.95	3.81	4.50
min	-60.5	-43.7	-98.2	-40.0	-55.7
25 %	-3.10	-0.400	-2.30	-2.50	-1.70
50 %	-0.400	1.10	-0.900	-1.00	0.00
75 %	3.00	2.70	0.500	0.300	1.50
max	209	60.4	61.2	92.8	94.2

Cuadro 2: Estadísticas Descriptivas por sujeto control (Parte 2/2)

Métrica	MGN	MJN	MMA	RAN	VCN
count	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6
mean	0.279	-2.71	-2.63	-1.70	-3.56
std	3.65	4.61	1.84	4.12	2.64
min	-33.7	-48.6	-21.6	-49.2	-48.0
25 %	-1.30	-5.10	-3.50	-3.50	-4.80
50 %	0.500	-2.80	-2.60	-1.70	-3.40
75 %	2.10	-0.500	-1.70	0.00	-2.20
max	46.2	98.2	33.5	60.3	81.1

En ambas tablas (Cuadro 1 y Cuadro 2) se presentan los momentos estadísticos listados a continuación:

- count: refiriéndose a la cantidad de datos con las que cuenta la muestra.

Cuadro 3: Estadísticas Descriptivas por sujeto control

Métrica	AEF	CLM	FGV	JGM	LIV	PCM	RLM	RRM
count	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6	8.06e6
mean	-1.49	-2.56	-1.89	-0.340	-9.83	1.66	-1.67	-13.3
std	4.02	4.07	2.82	5.50	4.45	4.69	6.26	3.94
min	-62.7	-58.5	-36.3	-45.9	-51.2	-98.5	-132	-65.5
25 %	-2.50	-3.80	-3.40	-2.50	-11.5	-0.100	-2.80	-14.6
50 %	-1.40	-2.40	-2.20	-0.500	-10.3	1.30	-1.50	-13.8
75 %	-0.400	-1.00	-0.700	1.50	-8.60	2.90	-0.100	-12.9
max	336	60.5	53.4	96.4	38.9	108	410	53.4

- mean: refiriéndose a la media de los datos.
- std: refiriéndose a la desviación estándar.
- min: refiriéndose al valor mínimo que presenta la muestra.
- 25 %: refiriéndose al primer cuartil.
- 50 %: refiriéndose al segundo cuartil.
- 75 %: refiriéndose al tercer cuartil.
- max: refiriéndose al valor máximo que presenta la muestra.

3. Clasificador Random Forest

En este trabajo se decidió usar el algoritmo de Random Forest el cual es un algoritmo de aprendizaje automático (machine learning) utilizado para clasificar y pronosticar. Esta técnica utiliza el concepto de árboles de decisión, construyendo una colección de árboles de decisión y agregando sus resultados para generar la predicción definitiva. Cada árbol de decisión dentro de un bosque aleatorio se construye utilizando subconjuntos aleatorios de datos, y cada árbol individual se entrena en una parte de todo el conjunto de datos. Posteriormente, los resultados de todos los árboles de decisión se amalgaman para derivar el pronóstico final. Uno de los beneficios de los bosques aleatorios es su capacidad para manejar datos desequilibrados. Además, los bosques aleatorios mitigan la cuestión del sobre ajuste mediante la capacitación de varios árboles de decisión en subconjuntos aleatorios de datos, lo que mejora su capacidad para generalizar a datos novedosos; una de las aplicaciones de este método es para diagnosticar pacientes y predecir resultados de pacientes salman2024random. Además se complementara con el método Leave One Out el cual es una técnica de estimación estadística que se aplica en diferentes campos que requieran una evaluación del rendimiento de un algoritmo de aprendizaje. Este se trata de un caso especial del método de validación cruzada k-fold que implica la partición del conjunto de datos originales k subconjuntos de tamaño (aproximada- mente) igual. El modelo se entrena k veces, utilizando cada subconjunto por turno como conjunto de prueba, y los subconjuntos restantes como conjunto de entrenamiento. La precisión total se puede obtener promediando los valores de precisión calculados

en cada subconjunto. En el caso de leave one out este es una validación cruzada k-fold calculada con $k = n$, donde n es el tamaño del conjunto de datos original. Por lo tanto cada conjunto de prueba tiene tamaño 1, lo que implica que el modelo se entrena n veces [brovelli2008accuracy](#).

4. clasificador KNN

La clasificación por vecino más cercano representa uno de los enfoques más sencillos y, a la vez, eficaces del aprendizaje automático. A diferencia de los algoritmos que construyen modelos complejos durante el entrenamiento, los métodos de vecino más cercano adoptan un enfoque más directo para la clasificación. El proceso de entrenamiento de los clasificadores por vecino más cercano (también denominados «basados en instancias» o «basados en memoria») es notablemente sencillo: 3 consiste simplemente en almacenar todos los ejemplos de entrenamiento en una estructura de datos adecuada para su posterior recuperación. Esto contrasta marcadamente con otros algoritmos de clasificación que crean modelos abstractos durante el entrenamiento. Lo que hace único al método del vecino más cercano es que pospone la mayor parte del trabajo computacional hasta el momento de la clasificación. Cuando un nuevo ejemplo necesita ser clasificado, el algoritmo identifica los k ejemplos de entrenamiento más similares a la nueva instancia; estos son sus « k vecinos más cercanos». A continuación, se determina la clase del nuevo ejemplo basándose en estos vecinos. El enfoque básico se limita a contar la clase mayoritaria entre los vecinos, pero las implementaciones más sofisticadas utilizan la ponderación por distancia. Con la ponderación por distancia, los vecinos físicamente más cercanos al ejemplo objetivo tienen mayor influencia en la decisión de clasificación. En nuestro ejemplo del correo electrónico, si el único vecino «no spam» estuviera mucho más cerca de nuestro nuevo correo electrónico que los dos vecinos «spam», un enfoque ponderado por distancia podría seguir clasificando el nuevo correo electrónico como «no spam». La selección del valor adecuado para k depende del contexto: no existe un número óptimo universal. Con $k = 1$, la clasificación se basa únicamente en el único ejemplo más cercano, lo que podría ser sensible al ruido. Con valores de k más altos, el algoritmo tiene en cuenta más vecinos, pero puede difuminar los límites entre clases. Para nuestro ejemplo del correo electrónico, un conjunto de datos muy pequeño podría funcionar mejor con $k = 3$, mientras que un conjunto de datos más grande podría beneficiarse de $k = 15$ o superior

5. Desviación estandar a largo y corto plazo

Cada intervalo $R - R$ representa el tiempo entre latidos cardíacos consecutivos, y la secuencia de estos intervalos puede analizarse como una serie temporal con propiedades dinámicas [Tayel2015](#):

$$R_1, R_2, R_3, \dots, R_n$$

donde cada R_i corresponde al tiempo transcurrido entre el latido i y el latido $i + 1$.

A partir de esta serie pueden obtenerse medidas que caracterizan la variabilidad a corto y largo plazo.

SD1 (variabilidad a corto plazo)

SD1 cuantifica la variabilidad rápida entre intervalos consecutivos, es decir, la variación instantánea de un latido al siguiente [RodriguezBenitez2016](#). Se define como:

$$SD1 = \sqrt{\frac{1}{2} \sigma_{\Delta}^2} \quad (1)$$

donde σ_{Δ} es la desviación estándar de las diferencias sucesivas $R_{n+1} - R_n$.

Un valor alto de SD1 indica mayor variabilidad *beat-to-beat*, asociada principalmente con la actividad parasimpática del sistema nervioso autónomo Almirall1995, Jimenez2020.

SD2 (variabilidad a largo plazo)

SD2 refleja la variabilidad global de la serie temporal, capturando fluctuaciones de mayor escala temporal RodriguezBenitez2016. Se calcula como:

$$SD2 = \sqrt{2\sigma^2 - SD1^2} \quad (2)$$

donde σ es la desviación estándar total de la serie R_n .

Un valor alto de SD2 indica mayor variabilidad a largo plazo, relacionada con cambios emocionales, actividad física o alteraciones del ritmo cardíaco Veloza2019. Por el contrario, valores bajos pueden asociarse con predominio simpático Jimenez2020.

6. Resultados

Una vez con esto procedimos a usar las metricas SD1 y SD2 para hacer una clasificacion de nuestros datos, primero, obtuvimos los SD1 y SD2 para cada sujeto y cada nodo dado que son una gran cantidad de datos a continuacion solo se presentan la informacion de los primeros nodos.

Cuadro 4: Valores de SD1 por sujeto control - Nodos C3 a F4

Persona	C3	C4	CZ	F3	F4
EMV	0.8826	0.6504	0.5307	2.0511	1.4118
GH2	1.1255	0.7941	0.6204	1.2813	0.8536
GUR	0.8111	0.7287	0.5889	1.2971	1.0394
JAL	0.1724	0.1760	0.1525	0.1917	0.1722
JAN	0.2843	0.5670	0.2766	0.3238	0.8579
MGN	0.1631	0.1550	0.1559	0.2360	0.3016
MJN	0.2275	0.3874	0.1925	0.3752	0.3050
MMA	0.3375	0.3271	0.2239	0.3374	0.3861
RAN	0.6604	0.4555	0.3940	0.5738	0.6582
VCN	3.2163	0.6690	0.9445	3.6138	1.2387

Cuadro 5: Valores de SD2 por sujeto - Nodos C3 a F4

Persona	C3	C4	CZ	F3	F4
EMV	2.6623	2.7021	2.7963	3.9621	5.2372
GH2	2.9317	2.8607	2.7682	4.0477	4.2576
GUR	8.2427	8.2315	8.2305	8.6304	8.7627
JAL	2.2067	2.4451	2.7602	4.2273	4.8202
JAN	3.0633	3.2070	3.1277	4.0145	3.8344
MGN	3.1882	3.5294	2.9507	3.7230	6.7881
MJN	3.0583	2.7824	2.4490	4.1814	3.7262
MMA	1.7083	1.6141	1.8008	1.9580	2.0338
RAN	2.4456	3.2833	2.7073	3.3289	5.7529
VCN	2.7899	1.7255	1.7045	3.4208	2.1108

Cuadro 6: Valores de SD1 por sujeto DCL - Nodos C3 a F4

Persona	C3	C4	CZ	F3	F4
AEF	0.2349	0.2883	0.2153	0.3263	0.4077
CLM	0.2887	0.3060	0.2414	0.2835	0.2897
FGV	0.3798	0.3797	0.3471	0.5096	0.7053
JGM	0.7672	0.9304	0.4838	1.0032	1.2345
LIV	0.3173	0.3777	0.3363	0.4066	0.3927
PCM	1.0591	0.9398	0.6573	1.6471	1.5755
RLM	0.2198	0.2246	0.1929	0.3291	0.3886
RRM	0.7946	0.8183	0.6009	0.7816	0.7177

Cuadro 7: Valores de SD2 por sujeto DCL - Nodos C3 a F4

Persona	C3	C4	CZ	F3	F4
AEF	2.0202	1.6376	1.8530	3.2175	3.1491
CLM	2.4997	2.9559	2.7775	3.6257	4.3958
FGV	2.3190	1.8103	2.1587	3.3382	3.0057
JGM	5.4872	4.7901	4.3497	5.9940	5.8812
LIV	5.3111	4.8494	4.9797	5.9089	6.0851
PCM	4.8881	4.9062	3.9286	6.9373	7.2490
RLM	5.2707	5.0991	5.2509	6.2569	5.8319
RRM	2.0499	2.3600	2.0627	2.9606	2.8267

Ahora usando el KNN hay dos formas de proceder una vez obtuvimos las metricas SD1 y SD2 la primera es clasificando usando la media de SD1 y SD2 por cada sujeto y usando un solo sujeto como prueba y el resto como entrenamiento, o bien usar todos los valores de SD1 y SD2, es decir considerar cada valor de SD1 y SD2 de cada nodo y de cada persona, para el primer caso tenemos lo

siguiente. Considerando $k = 3$ el modelo KNN obtuvo una precisión total de 0,667 es decir clasificó 12 sujetos bien del total de 18 sujetos de la siguiente manera:

Cuadro 8: Clasificación de sujetos - Real vs Predicho

Sujeto	Real	Predicho
EMV	Control	DCL
GH2	Control	DCL
GUR	Control	DCL
JAL	Control	Control
JAN	Control	Control
MGN	Control	Control
MJN	Control	Control
MMA	Control	DCL
RAN	Control	Control
VCN	Control	DCL
AEF	DCL	DCL
CLM	DCL	Control
FGV	DCL	DCL
JGM	DCL	DCL
LIV	DCL	DCL
PCM	DCL	DCL
RLM	DCL	DCL
RRM	DCL	DCL

De donde obtenemos la matriz de confusión:

Cuadro 9: Clasificación de sujetos - Real vs Predicho (Random Forest)

	Control	DCL
Control	5	5
DCL	1	7

Ahora si procedemos con la segunda opción obtenemos la siguiente información:

Cuadro 10: Clasificación de sujetos - Real vs Predicho

Sujeto	Real	Predicho
EMV	Control	Control
GH2	Control	Control
GUR	Control	DCL
JAL	Control	DCL
JAN	Control	Control
MGN	Control	DCL
MJN	Control	Control
MMA	Control	DCL
RAN	Control	Control
VCN	Control	Control
AEF	DCL	Control
CLM	DCL	Control
FGV	DCL	Control
JGM	DCL	Control
LIV	DCL	DCL
PCM	DCL	Control
RLM	DCL	DCL
RRM	DCL	Control

De donde obtenemos la matriz de confusión:

Cuadro 11: Clasificación de sujetos - Real vs Predicho (Random Forest)

	Control	DCL
Control	6	4
DCL	7	1

En esta opción obtuvimos que la precisión total del modelo es de solo 0,444 es decir de los 18 sujetos a clasificar solamente clasificó bien 8, lo cual nos indica que bajo las métricas que trabajamos es mejor considerar las medias de SD1 y SD2 para obtener una mayor precisión. Ahora con el algoritmo de random forest los resultados que se obtuvieron no fueron relevantes sin embargo sirve para hacer una buena comparativa y analizar la situación. De igual forma considerando solamente las medias para SD1 y SD2 se obtuvo lo siguiente:

Cuadro 12: Clasificación de sujetos - Real vs Predicho (Random Forest)

Sujeto	Real	Predicho
EMV	Control	Control
GH2	Control	DCL
GUR	Control	DCL
JAL	Control	Control
JAN	Control	Control
MGN	Control	Control
MJN	Control	Control
MMA	Control	DCL
RAN	Control	Control
VCN	Control	DCL
AEF	DCL	Control
CLM	DCL	Control
FGV	DCL	Control
JGM	DCL	Control
LIV	DCL	DCL
PCM	DCL	Control
RLM	DCL	Control
RRM	DCL	Control

De donde obtuvimos la matriz de confusión siguiente

Cuadro 13: Clasificación de sujetos - Real vs Predicho (Random Forest)

	Control	DCL
Control	6	4
DCL	7	1

De donde se obtuvo una precisión total del 0,389 es decir de los 18 sujetos solamente clasificó bien a 7. Con el otro caso, es decir, usando todos los nodos se obtuvo:

Cuadro 14: Clasificación de sujetos - Real vs Predicho (Random Forest)

Sujeto	Real	Predicho
EMV	Control	Control
GH2	Control	DCL
GUR	Control	DCL
JAL	Control	Control
JAN	Control	DCL
MGN	Control	Control
MJN	Control	Control
MMA	Control	DCL
RAN	Control	DCL
VCN	Control	Control
AEF	DCL	Control
CLM	DCL	Control
FGV	DCL	Control
JGM	DCL	DCL
LIV	DCL	DCL
PCM	DCL	Control
RLM	DCL	Control
RRM	DCL	Control

De donde obtuvimos la matriz de confusión siguiente

Cuadro 15: Clasificación de sujetos - Real vs Predicho (Random Forest)

	Control	DCL
Control	5	5
DCL	6	2

Dando una precisión total del 0.389, es decir de igual forma solo clasificó bien 7 sujetos de los 18 que hay.

7. Conclusión

Como pudimos observar el algoritmo KNN funcionó mejor para clasificar nuestros sujetos si bien la precisión no fue la deseada, depende del contexto si este resultado puede llegar a ser aceptable. Por otro lado el algoritmo random forest clasificó de forma errónea la mayoría de los sujetos sin embargo este no fue descartado pues sirve para ejemplificar que se debe considerar opciones para trabajar los modelos, pues en el trabajo anterior el algoritmo random forest tuvo mejores resultados que en este trabajo, lo cual nos ayuda en entender y prever alternativas a la hora de trabajar en problemas de clasificación.

Pueden encontrar lo necesario para replicar todos los resultados en github